Программирование на C для PostgreSQL

Alexander Korotkov

Postgres Professional

2015

Developers 1996

PGCon 2015 Developers Meeting

Oleg Bartunov, Teodor Sigaev

- Locale support
- Extendability (indexing)
  - GiST (KNN), GIN, SP-GiST
- Full Text Search (FTS)
- Jsonb, VODKA
- Extensions:
  - intarray
  - pg_trgm
  - ltree
  - hstore
  - plantuner

https://www.facebook.com/oleg.bartunov
obartunov@postgrespro.ru,
teodor@postgrespro.ru
https://www.facebook.com/groups/postgresql/

Alexander Korotkov

- Indexed regexp search
- GIN compression & fast scan
- Fast GiST build
- Range types indexing
- Split for GiST
- Indexing for jsonb
- jsquery
- Generic WAL + create am (WIP)

a.korotkov@postgrespro.ru

Простейший пример: сложение двух чисел

```c
#include ”postgres.h”
#include ”fmgr.h”

PG_MODULE_MAGIC;
PG_FUNCTION_INFO_V1(add);

Datum
add(PG_FUNCTION_ARGS)
{
    int32 arg1 = PG_GETARG_INT32(0),
          arg2 = PG_GETARG_INT32(1);
    PG_RETURN_INT32(arg1 + arg2);
}
```

Datum

- Datum – это unsigned integer достаточной длины, чтобы хранить в себе pointer.

```
typedef uintptr_t Datum;
```

- Любое значение PostgreSQL может быть приведено к типу Datum и наоборот. Для этого используются макросы DatumGet*(x) и *GetDatum(x).
- Значения, которые помещаются в Datum, могут быть переданы по значению, остальные передаются по указателю.
- Аргументы функции и возвращаемые значения передаются как Datum.

PostgreSQL calling convention version 1

- Параметры передаются через специальную структуру

```
/* Standard parameter list for fmgr-compatible functions */
#define PG_FUNCTION_ARGS FunctionCallInfo fcinfo
typedef struct FunctionCallInfoData *FunctionCallInfo;
```

- Для доступа к параметрам заведены макросы PG_GET_ARG_*(n)

```
#define PG_GETARG_DATUM(n)  (fcinfo->arg[n])
#define PG_GETARG_INT32(n)  DatumGetInt32(PG_GETARG_DATUM(n))
```

- Для возвращения результата используются макросы PG_RETURN_*(x)

```
#define PG_RETURN_DATUM(x)  return (x)
#define PG_RETURN_INT32(x)  return Int32GetDatum(x)
```

- PG_FUNCTION_INFO_V1(funcname) указывает на использование calling convention version 1, был ещё version 0...

PG_MODULE_MAGIC

Введён начиная с версии 8.2 и позволяет автоматически проверять совместимость модуля со сборкой PostgreSQL.

```
/* The actual data block contents */
#define PG_MODULE_MAGIC_DATA \
{ \
    sizeof(Pg_magic_struct), \
    PG_VERSION_NUM / 100, \
    FUNC_MAX_ARGS, \
    INDEX_MAX_KEYS, \
    NAMEDATALEN, \
    FLOAT4PASSBYVAL, \
    FLOAT8PASSBYVAL \
}
```

PROFESSIONAL Postgres

pg_aa

Из чего состоит расширение pg_aa?

- `Makefile` – файл для сборки с помощью GNU make
- `pg_aa–1.0.sql` – SQL-скрипт, создающий объекты БД
- `pg_aa.c` – исходный текст на C
- `pg_aa.control` – control file с параметрами
- `sql/pg_aa.sql` – регрессионные тесты
- `data/logo.data` – данные для регрессионных тестов
- `expected/pg_aa.out` – ожидаемые результаты

Makefile

```
# pg_aa/Makefile

MODULE_big = pg_aa     # Название собираемого .so файла
OBJS = pg_aa.o         # Список .o файлов, из которых собирается .so
EXTENSION = pg_aa      # Название самого extension'а
DATA = pg_aa--1.0.sql # Файлы, которые нужно скопировать в
SHLIB_LINK = -lgd -laa -lcaca # Библиотеки, которые нужно подключить
REGRESS = pg_aa        # Список тестов

ifdef USE_PGXS # Если USE_PGXS установлено, то нужные для сборки файлы
               # PostgreSQL находятся с помощью утилиты pg_config
    PG_CONFIG = pg_config
    PGXS := $(shell $(PG_CONFIG) --pgxs)
    include $(PGXS)
else           # Если нет, то считается что расширение помещено в папку
               # contrib исходников PostgreSQL
    subdir = contrib/pg_aa
    top_builddir = ../..
    include $(top_builddir)/src/Makefile.global
    include $(top_srcdir)/contrib/contrib-global.mk
endif
```

pg_aa.control

Этот файл является входной точкой для команд (CREATE|ALTER|DROP) EXTENSION.

```
# pg_aa extension
comment = 'ASCII art extension for PostgreSQL'
default_version = '1.0'           # Версия SQL-скрипта, которая
                                  # будет устанавливаться по-умолчанию
module_pathname = '$libdir/pg_aa' # Значение, которое будет
                                  # подставляться в MODULE_PATHNAME
                                  # SQL-скрипта
relocatable = true                # Можно ли перемещать extension в
                                  # другую схему
```

pg_aa--1.0.sql

```
/* pg_aa/pg_aa--1.0.sql */

-- complain if script is sourced in psql, rather than via CREATE EXTENSION
\echo Use "CREATE EXTENSION pg_aa" to load this file. \quit

--
--  PostgreSQL code for pg_aa.
--

CREATE FUNCTION aa_out(bytea, int4)   -- Функция вывода с помощью libaa
RETURNS text
AS 'MODULE_PATHNAME'
LANGUAGE C IMMUTABLE STRICT;

CREATE FUNCTION caca_out(bytea, int4) -- Функция вывода с помощью libcaca
RETURNS text
AS 'MODULE_PATHNAME'
LANGUAGE C IMMUTABLE STRICT;
```

Extension и зависимости

Связь между extension’ом и его объектами хранится в pg_depend.

Благодаря этому:

- DROP EXTENSION удаляет весь extension и ему не нужен для этого отдельный скрипт.
- Нельзя случайно удалить часть extension’а.
- В SQL dump не попадают объекты extension’а, а только команда CREATE EXTENSION.

```
# SELECT p.proname
  FROM pg_depend d
       JOIN pg_extension e ON e.oid = d.refobjid
       JOIN pg_proc p ON p.oid = d.objid
  WHERE e.extname = 'pg_aa';
 proname
----------
 aa_out
 caca_out
(2 rows)
```

aa_out – инициализация и отрисовка

```
Datum
aa_out(PG_FUNCTION_ARGS)
{
    bytea *img = PG_GETARG_BYTEA_PP(0); /* Получаем значения аргументов */
    int    width = PG_GETARG_INT32(1);
...
    old_locale = pstrdup(setlocale(LC_CTYPE, NULL));
    setlocale(LC_CTYPE, "C"); /* libaa нормально работает только в
                               * локали C */
    im = gdImageCreateFromPngPtr(VARSIZE_ANY_EXHDR(img),
                                 VARDATA_ANY(img));
...
    context = aa_init(&mem_d, &params, NULL);
...
    for (i = 0; i < gdImageSX(tb); i++) /* Отрисовываем */
    {
        for (j = 0; j < gdImageSY(tb); j++)
            aa_putpixel(context, i, j, get_intensity(tb, i, j));
    }
...
```

aa_out – возвращение результата

```
...
    /* Получаем вывод и разбавляем его переводами строк */
    s = (char *)aa_text(context);
    result = (text *)palloc(VARHDRSZ +
        (width + 1) * height * MAX_MULTIBYTE_CHAR_LEN);
    SET_VARSIZE(result, d - (char *)result);
    d = VARDATA(result);
    for (i = 0; i < height; i++)
    {
        if (i > 0)
            *d++ = '\n';
        for (j = 0; j < width; j++)
            *d++ = *s++;
    }
...
    setlocale(LC_CTYPE, old_locale); /* Возвращаем локаль назад */
    pfree(old_locale);
    PG_RETURN_TEXT_P(result);
}
```

Varlena значения

- Значения с не фиксированной длиной хранятся как заголовок + данные.
- Заголовок занимает 4 байта (VARHDRSZ), хранит флаги и длину. Начиная с 8.3 для коротких значений есть 1-байтовая версия заголовка.
- В заголовке также содержится признак сжатого и TOAST значений.
- VARSIZE*(x) – длина, VARDATA*(x) – получение указателя на данные, SET_VARSIZE*(x) – установить длину.

Как использовать aa_out

```
psql test
# CREATE EXTENSION pg_aa;
CREATE EXTENSION
# CREATE TABLE logo (name text NOT NULL, data bytea NOT NULL);
CREATE TABLE
# \q

echo -e 'PostgreSQL\t\\\x'`xxd -p pg_logo.png | tr -d '\r\n'` |
    psql test -c 'COPY logo FROM stdin;'

psql test
# SELECT aa_out(data, 10) FROM logo;
   aa_out
------------
 _mixWQIxm,+
 )WQenWx3i(+
 )%QoxWWnr +
  ]"N?%W7"`+
     WiQ'
(1 row)
```

libcaca и caca_out

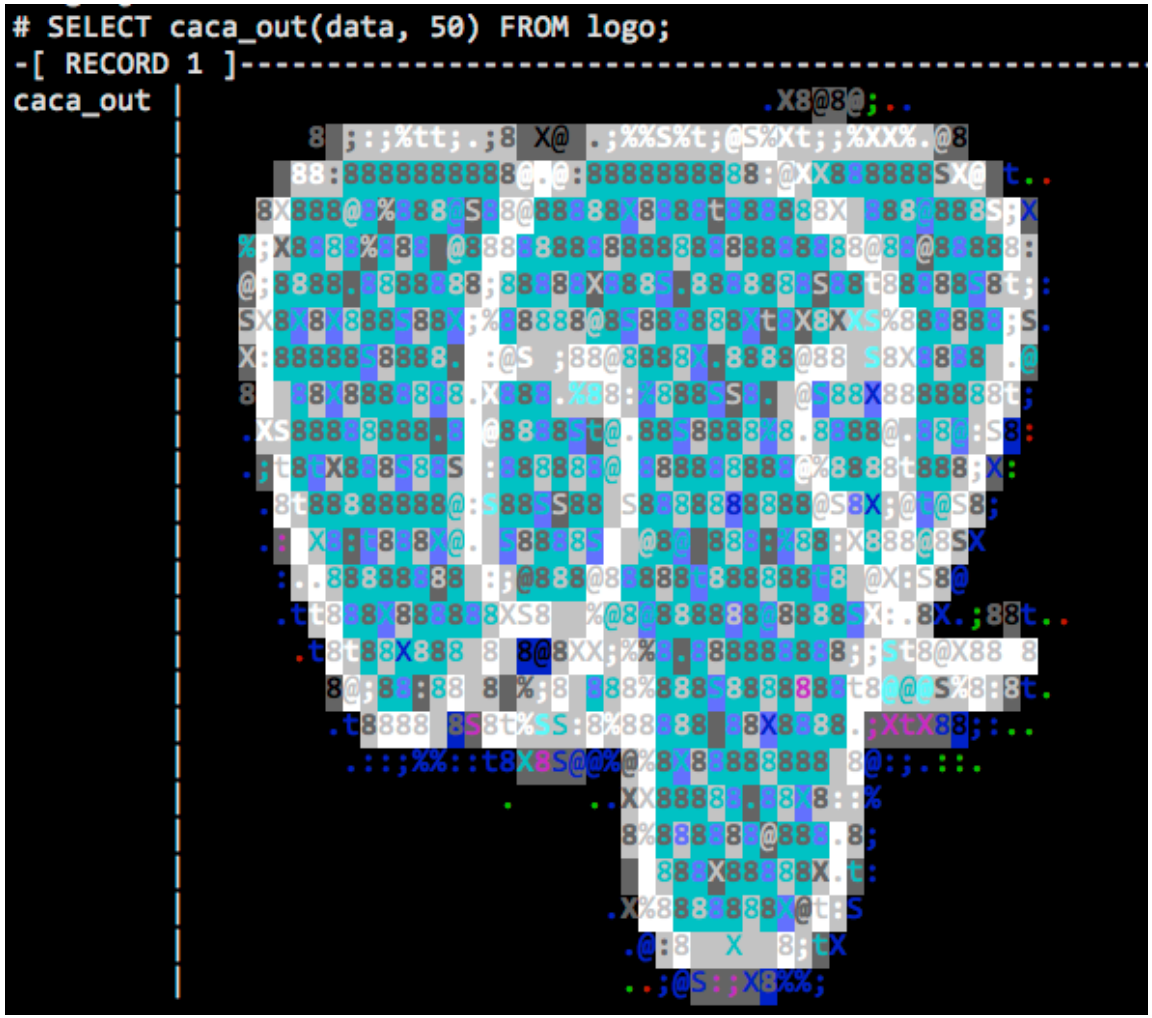

Как такое возможно?

Как это получилось?

~/.psqlrc

```
-- Pager всегда включен
\pset pager always
-- Убираем экранирование с символа escape
\setenv PAGER 'sed "s/\\\\\\\\x1B/`echo "\033"`/g" | less'
-- Настройки для less: отображение длинных линий, цветов т.д.
\setenv LESS '-iMSx4R -FX'
```

Регрессионные тесты: SQL

sql/pg_aa.sql

```
CREATE EXTENSION pg_aa;

CREATE TABLE logo (name text NOT NULL, data bytea NOT NULL);
\copy logo FROM 'data/logo.data'

SELECT aa_out(data, 20) FROM logo ORDER BY name;
SELECT aa_out(data, 40) FROM logo ORDER BY name;

SELECT caca_out(data, 20) FROM logo ORDER BY name;
SELECT caca_out(data, 40) FROM logo ORDER BY name;
```

Регрессионные тесты: ожидаемый результат

expected/pg_aa.out

```
CREATE EXTENSION pg_aa;
CREATE TABLE logo (name text NOT NULL, data bytea NOT NULL);
\copy logo FROM 'data/logo.data'
SELECT aa_out(data, 20) FROM logo ORDER BY name;
        aa_out
----------------------
         qyggwp+      +
        jWQQU$Qr      +
        ]p%Y]nQk      +
        .L,.uJQQ,     +
       qZ'W'= )QQc    +
      j$'      ?m$g,  +
     qh'        $SQ[  +
   -.T1p       ,dmmt  +
 ](‘  )$c    yf]!')_,+
 ]'    /\ggaaQf   ..‘+
 W^-^y../""""""""s..-+
...
```

complex type

```c
typedef struct Complex
{
    double      x;
    double      y;
}   Complex;
```

```
CREATE TYPE complex (
   internallength = 16, -- тип фиксированной длины
   input = complex_in, -- преобразование в текст
   output = complex_out, -- преобразование из текста
   receive = complex_recv, -- пересылка по сети
   send = complex_send, -- получение по сети
   alignment = double -- выравнивание
);
```

Input function

Преобразование cstring => complex. Если что-то пошло не так, то кидаем ошибку с уровнем ERROR.

```
Datum
complex_in(PG_FUNCTION_ARGS)
{
    char        *str = PG_GETARG_CSTRING(0);
    double       x,
                 y;
    Complex     *result;

    if (sscanf(str, " ( %lf , %lf )", &x, &y) != 2)
        ereport(ERROR,
                (errcode(ERRCODE_INVALID_TEXT_REPRESENTATION),
                 errmsg("invalid input syntax for complex: \"%s\"",
                        str)));

    result = (Complex *) palloc(sizeof(Complex));
    result->x = x;
    result->y = y;
    PG_RETURN_POINTER(result);
}
```

Output function

Преобразование complex => cstring.

```
Datum
complex_out(PG_FUNCTION_ARGS)
{
    Complex    *complex = (Complex *) PG_GETARG_POINTER(0);
    char       *result;

    result = psprintf("(%g,%g)", complex->x, complex->y);
    PG_RETURN_CSTRING(result);
}
```

Send function

Специальные макросы pq_send*(buf, value) для кроссплатформенной отправки значений.

```
Datum
complex_send(PG_FUNCTION_ARGS)
{
    Complex    *complex = (Complex *) PG_GETARG_POINTER(0);
    StringInfoData buf;

    pq_begintypsend(&buf);
    pq_sendfloat8(&buf, complex->x);
    pq_sendfloat8(&buf, complex->y);
    PG_RETURN_BYTEA_P(pq_endtypsend(&buf));
}
```

Receive function

Специальные макросы pq_getmsg*(buf) для кроссплатформенного получения значений.

```
Datum
complex_recv(PG_FUNCTION_ARGS)
{
    StringInfo  buf = (StringInfo) PG_GETARG_POINTER(0);
Complex    *result;

    result = (Complex *) palloc(sizeof(Complex));
    result->x = pq_getmsgfloat8(buf);
    result->y = pq_getmsgfloat8(buf);
    PG_RETURN_POINTER(result);
}
```

Оператор сложения

```c
Datum /* Код оператора на C */
complex_add(PG_FUNCTION_ARGS)
{
    Complex    *a = (Complex *) PG_GETARG_POINTER(0);
    Complex    *b = (Complex *) PG_GETARG_POINTER(1), *result;
    result = (Complex *) palloc(sizeof(Complex));
    result->x = a->x + b->x;
    result->y = a->y + b->y;
    PG_RETURN_POINTER(result);
}
```

```
CREATE FUNCTION complex_add(complex, complex)
   RETURNS complex
   AS 'MODULE_PATHNAME'
   LANGUAGE C IMMUTABLE STRICT;

CREATE OPERATOR + ( -- Определение оператора
   leftarg = complex, rightarg = complex, -- Типы аргументов
   procedure = complex_add, -- Функция, которая выполняет оператор
   commutator = + -- Коммутатор (есть ещё negator)
);
```

Оператор умножения

```c
Datum /* Код оператора на C */
complex_mult(PG_FUNCTION_ARGS)
{
    Complex    *a = (Complex *) PG_GETARG_POINTER(0);
    Complex    *b = (Complex *) PG_GETARG_POINTER(1);
    Complex    *result;
    result = (Complex *) palloc(sizeof(Complex));
    result->x = a->x * b->x - a->y * b->y;
    result->y = a->x * b->y + a->y * b->x;
    PG_RETURN_POINTER(result);
}
```

```
CREATE FUNCTION complex_mult(complex, complex)
   RETURNS complex
   AS 'MODULE_PATHNAME'
   LANGUAGE C IMMUTABLE STRICT;

CREATE OPERATOR * ( -- Определение оператора
   leftarg = complex, rightarg = complex, -- Типы аргументов
   procedure = complex_mult, -- Функция, которая выполняет оператор
   commutator = * -- Коммутатор (есть ещё negator)
);
```

Использование операторов

Теперь мы можем преобразовывать комплексные числа из строки и в строку, а также использовать операторы + и *.

```
# SELECT '(1, 1)'::complex + '(-1,1)'::complex;
 ?column?
----------
 (0,2)
(1 row)

# SELECT '(1, 1)'::complex * '(-1,1)'::complex;
 ?column?
----------
 (-2,0)
(1 row)
```

Операторы сравнения

Сравнение комплексных чисел по модулю.

```
Datum
complex_abs_lt(PG_FUNCTION_ARGS)
{
    Complex    *a = (Complex *) PG_GETARG_POINTER(0);
    Complex    *b = (Complex *) PG_GETARG_POINTER(1);
    PG_RETURN_BOOL(complex_abs_cmp_internal(a, b) < 0);
}
```

```
CREATE FUNCTION complex_abs_lt(complex, complex) RETURNS bool
   AS 'MODULE_PATHNAME' LANGUAGE C IMMUTABLE STRICT;

CREATE OPERATOR < (
   leftarg = complex, rightarg = complex, procedure = complex_abs_lt,
   commutator = > , negator = >= ,
   restrict = scalarltsel, join = scalarltjoinsel
);
```

Аналогичным образом вводятся <, <=, =, >=, >.

Operator class (opclass)

- Opclass – мостик между типом индекса (access method) и типом данных.
- Любой индекс строится с использованием opclass'а.
- Если конкретный opclass не задан, то используется opclass по-умолчанию.
- Кроме этого btree и hash opclass'ы используются при исполнении запросов для сортировки и хэширования.

```
CREATE OPERATOR CLASS complex_abs_ops
    DEFAULT FOR TYPE complex USING btree AS
        -- Операторы, которые поддерживает opclass
        OPERATOR        1       < ,
        OPERATOR        2       <= ,
        OPERATOR        3       = ,
        OPERATOR        4       >= ,
        OPERATOR        5       > ,
        -- Функция сравнения
        FUNCTION        1       complex_abs_cmp(complex, complex);
```

Использование индекса

```
# CREATE INDEX complex_test_v_idx ON complex_test(v complex_abs_ops);
# SELECT * FROM complex_test WHERE v > '(0.5, 0.5)' ORDER BY v LIMIT 5;
          v
----------------------
 (0.344993,0.617238)
 (0.0314643,0.706409)
 (0.472858,0.525748)
 (0.649746,0.278991)
 (0.282167,0.648376)
(5 rows)

 Limit  (cost=0.42..1.11 rows=10 width=16)
 (actual time=0.054..0.068 rows=10 loops=1)
   ->  Index Only Scan using complex_test_v_idx on complex_test
       (cost=0.42..41539.82 rows=605000 width=16)
       (actual time=0.054..0.066 rows=10 loops=1)
         Index Cond: (v > '(0.5,0.5)'::complex)
         Heap Fetches: 10
 Planning time: 0.198 ms
 Execution time: 0.099 ms
```

Set-returning functions (SRF)

- Возвращают несколько значений (строк).
- Функция вызывается отдельно на каждую возвращаемую строку.
- Память, выделенную для возврата одной строки, не обязательно освобождать. Контекст памяти очищается между вызовами. Для памяти, которая должна сохраняться между вызовами, есть отдельный контекст.

SRF на C (1/3)

```c
/* Контекст, который будет сохраняться между вызовами фукнции */
typedef struct
{
    Complex current; /* Текущее значение*/
    Complex step;    /* Шаг */
} gsc_fctx;

Datum
generate_series_complex(PG_FUNCTION_ARGS)
{
    FuncCallContext *funcctx;
    gsc_fctx *fctx;

    if (SRF_IS_FIRSTCALL()) /* Первоначальная инициализация */
    {
        /* Достаём значения аргументов */
        Complex *start = (Complex *)PG_GETARG_POINTER(0);
        Complex *finish = (Complex *)PG_GETARG_POINTER(1);
        int64 count = PG_GETARG_INT64(2);
        MemoryContext oldcontext;
......
```

SRF на C (2/3)

```
......
        funcctx = SRF_FIRSTCALL_INIT();
        /* Переключаемся в постоянный контекст памяти */
        oldcontext = MemoryContextSwitchTo(
                        funcctx->multi_call_memory_ctx);

        /* Заполняем данные контекста */
        fctx = (gsc_fctx *)palloc(sizeof(gsc_fctx));
        fctx->current = *start;
        fctx->step.x = (finish->x - start->x) / (double)(count - 1);
        fctx->step.y = (finish->y - start->y) / (double)(count - 1);
        funcctx->user_fctx = fctx;

        /* Переключаем контекст памяти обратно */
        MemoryContextSwitchTo(oldcontext);
        /* Заранее знаем, сколько значений вернём */
        funcctx->max_calls = count;;
    }
......
```

SRF на C (3/3)

```
.......
    funcctx = SRF_PERCALL_SETUP();
    fctx = funcctx->user_fctx;
    /* Нужно ещё возвращать значения? */
    if (funcctx->call_cntr < funcctx->max_calls)
    {
        /* Копируем текущее значение в текущий контекст памяти */
        Complex *result = (Complex *)palloc(sizeof(Complex));
        memcpy(result, &fctx->current, sizeof(Complex));
        /* Увеличиваем текущее значение */
        fctx->current.x += fctx->step.x;
        fctx->current.y += fctx->step.y;
        /* Возвращаем приготовленную копию */
        SRF_RETURN_NEXT(funcctx, PointerGetDatum(result));
    }
    else
    {
        SRF_RETURN_DONE(funcctx);
    }
}
```

SRF в работе

```
-- Определения на уровне SQL
CREATE FUNCTION generate_series_complex(complex, complex, bigint)
   RETURNS SETOF complex AS 'MODULE_PATHNAME'
   LANGUAGE C IMMUTABLE STRICT;
```

```
# SELECT * FROM generate_series_complex('(0, 0)', '(1, 1)', 5);
 generate_series_complex
-------------------------
 (0,0)
 (0.25,0.25)
 (0.5,0.5)
 (0.75,0.75)
 (1,1)
(5 rows)
```

Заключение

- Писать на C под PostgreSQL не так уж страшно.
- Можно начинать с расширений, постепенно преодолевая порог вхождения.
- Welcome to community!

С чего начать

- Материалы для начинающих:
  https://drive.google.com/open?id=1HwCauA_XUM7hCbzfAq-ofhhG8H1az372vnM75o4Loj8
- Реестр задач для начинающих:
  https://drive.google.com/open?id=1wzDlMF7NkZZC4Kp6m6KRaYeaSYyU6tKvRkDUlKOyCjs

JIT-компиляция: PGStrom

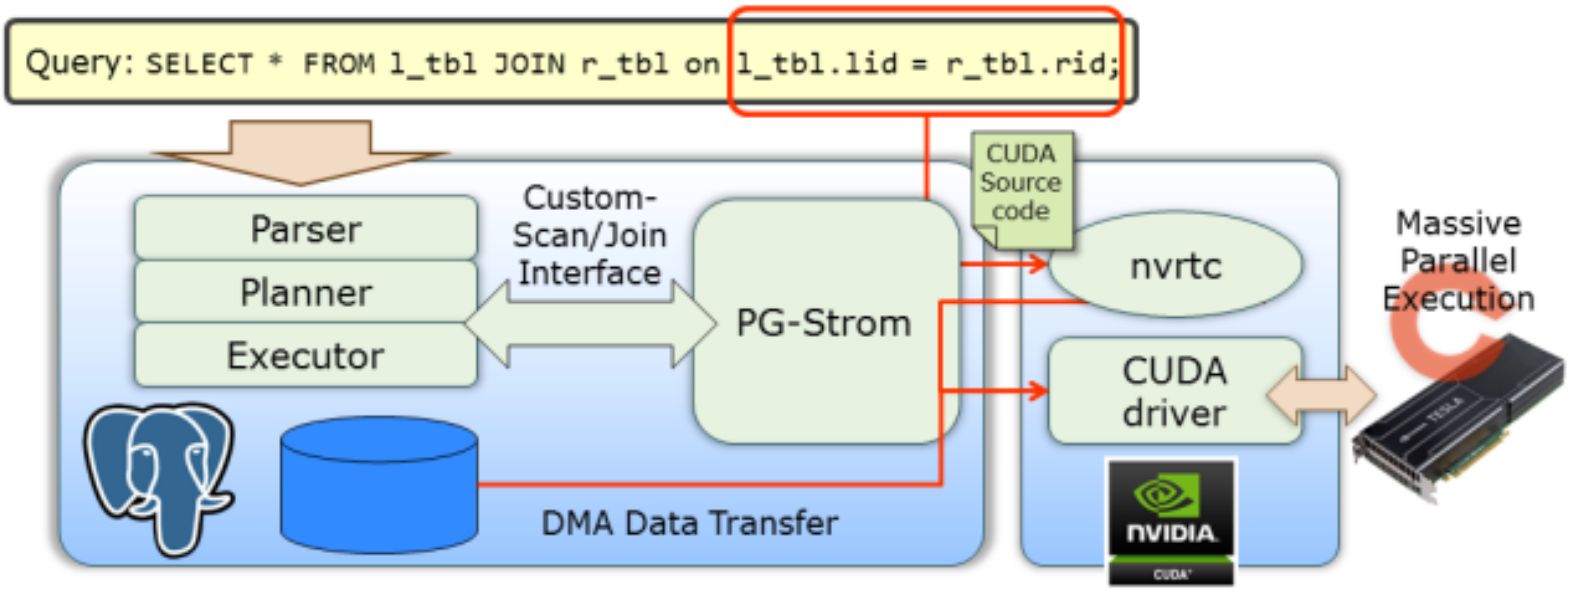

https://wiki.postgresql.org/wiki/PGStrom

- Уже есть JIT-компиляция для GPU!
- Сделано в виде расширения.

JIT-компиляция: с чего начать?

- Для начала можно реализовать JIT-компиляцию выражений.
- Можно сделать это в виде расширения.
- Можно подглядывать в PGStrom.

Спасибо за внимание!

и

Welcome on board!

Александр Коротков
a.korotkov@postgrespro.ru
ООО «Постгрес Профессиональный»
http://postgrespro.ru/